



Universidad de Jaén

Escuela Politécnica Superior de Jaén

Reproducción, evaluación y adaptación de modelos de seguimiento visual para escenarios Anti-UAV con imágenes térmicas

Autor: Álvaro Cobo Mayoral

Grado: Ingeniería en Informática

Directores: Antonio Jesús Rivera Rivas y Pedro González García
Departamento del director: Informática

Fecha: 3/11/2025

Licencia CC



CREA



UNIVERSIDAD DE JAÉN

D./D^a Antonio Jesús Rivera Rivas y D./D^a Pedro González García, tutor(es) del Trabajo Fin de Grado titulado: **Reproducción, evaluación y adaptación de modelos de seguimiento visual para escenarios Anti-UAV con imágenes térmicas**, que presenta Álvaro Cobo Mayoral, autoriza(n) su presentación para defensa y evaluación en la Escuela Politécnica Superior de Jaén.

Jaén, 3/11/2025

Agradecimientos

Incluir aquí los agradecimientos que se deseen, dedicatoria y cualquier otro texto de carácter personal.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

0.0.1. Imágenes térmicas en el espectro infrarrojo

Uno de los principales retos a los que se enfrentan los sistemas de seguimiento de UAVs es la condición del entorno. Un buen sistema SOT debe poder detectar y seguir objetivos en cualquier momento del día y bajo cualquier condición adversa (temperatura, humedad, temporal...), lo cual es especialmente complicado en las horas nocturnas o de poca luz natural, y en entornos con niebla, lluvia, rachas fuertes de viento y demás fenómenos ambientales. Estos factores no solo reducen a menudo la calidad de la imagen, sino que además introducen ruido y variaciones en la firma del objetivo. Es por esto que la tecnología de imágenes infrarrojas comenzó a ser muy relevante en este campo.

La tecnología de procesamiento de imágenes térmicas en el espectro infrarrojo (TIR) consiste en la reconstrucción de imágenes a través de la radiación infrarroja emitida por los objetos de la escena. Una de las principales ventajas de este proceso es su capacidad para no interferir directamente con el objetivo, ya que la radiación electromagnética es una propiedad física inherente a cualquier cuerpo con una temperatura por encima del cero absoluto. Al limitarse a recibir dicha señal sin emitir energía externa, los detectores TIR se clasifican como sistemas de detección pasivos, lo que los hace ideales para aplicaciones militares y de vigilancia.

Pese a todas sus ventajas, el proceso de obtención de estas imágenes requiere una serie de etapas de procesamiento debido al bajo contraste y a la escasa resolución de los detalles de la imagen. Estas etapas de procesamiento suelen llevarse a cabo a través técnicas de visión artificial (computer vision) y aprendizaje profundo (deep learning) [Hou et al. \(2022\)](#).

Tabla de contenidos

0.0.1. Imágenes térmicas en el espectro infrarrojo	2
1. INTRODUCCIÓN	13
1.1. Motivación	13
1.2. Objetivos	13
2. ANTECEDENTES	15
2.1. Orígenes de la tecnología UAV	15
2.2. Seguimiento de objetos individuales (SOT)	16
2.3. Clasificación de métodos SOT	17
2.3.1. Métodos basados en características	17
2.3.2. Métodos basados en segmentación	20
2.3.3. Métodos basados en estimación	22
2.3.4. Métodos basados en aprendizaje automático	24
2.3.4.1. Métodos generativos	25
2.3.4.2. Métodos de aprendizaje reforzado	25
2.3.4.3. Métodos discriminativos	27
3. OBJETIVOS	35
4. MATERIALES Y MÉTODOS	37
5. RESULTADOS	39
6. CONCLUSIONES	41
Bibliografía	43

Lista de figuras

2.1. Taxonomía de métodos de seguimiento visual	17
2.2. Diagrama de flujo del seguimiento de objetos basado en histogramas en el espacio de características de gradiente (Zhao, 2007). Fuente: Soleimanitaleb and Keyvanrad (2022)	19
2.3. Ejemplo de extracción de características mediante filtros de Gabor	19
2.4. Ejemplo de flujo óptico denso entre dos frames consecutivos	20
2.5. Esquema general del flujo de un método de seguimiento basado en segmentación <i>bottom-up</i>	21
2.6. Esquema general del flujo de un método de seguimiento basado en segmentación <i>joint-based</i>	22
2.7. Flujo refinado del filtro de Kalman: La predicción física se corrige mediante la medición real para obtener el estado óptimo. Inspirado en Soleimanitaleb and Keyvanrad (2022)	23
2.8. Flujo general del método de filtro de partículas basado en histogramas (Ding et al. (2016)).	24
2.9. Ejemplo del proceso de decisión en un método de seguimiento basado en aprendizaje por refuerzo. A partir del estado actual, el agente evalúa distintas acciones que generan nuevas hipótesis de localización. Cada una de estas hipótesis se asocia a una función de valor o recompensa (visualizada mediante mapas de calor), que mide la calidad de la localización.	26
2.10. Resumen del uso de máquinas de soporte vectorial para tareas de seguimiento Tian et al. (2007)	28
2.11. Ejemplo de red neuronal estándar con 3 capas ocultas IBM (sf)	29
2.12. Flujo general de un método de seguimiento profundo basado en extracción de características y modelado temporal. Ghaemmaghami (2017)	30
2.13. Representación de la estructura del modelo de red neuronal siamesa. Los datos se procesan de izquierda a derecha. El valor de la distancia coseno es una medida de la similitud entre el par de instancias de datos de entrada, como resultado final. Chicco (2021)	32

2.14. Representación de la estructura del modelo de red neuronal siamesa. Los datos se procesan de izquierda a derecha. El valor de la distancia coseno es una medida de la similitud entre el par de instancias de datos de entrada, como resultado final. Chicco (2021)	32
2.15. Se introduce en la red una zona de búsqueda del fotograma actual y un objetivo del fotograma anterior. La red aprende a comparar estos recortes para encontrar el objeto objetivo en la imagen actual Held et al. (2016) . . .	33

Lista de tablas

Lista de algoritmos

Lista de listados de código

Capítulo 1

INTRODUCCIÓN

1.1. Motivación

La proliferación de vehículos aéreos no tripulados (UAVs) o drones, ha generado una creciente preocupación en la sociedad debido a los riesgos potenciales que representan para la seguridad pública y nacional. Estos dispositivos, aunque tienen aplicaciones legítimas en áreas como la fotografía aérea, la agricultura de precisión y la entrega de paquetes, también pueden ser utilizados con fines malintencionados, como el espionaje, el contrabando o incluso [Hou et al. \(2022\)](#) ataques terroristas. La necesidad de desarrollar sistemas efectivos para detectar y rastrear estos vehículos se ha vuelto cada vez más urgente, desembocando en la disciplina de la visión por computador y el aprendizaje profundo [HD Drones \(sf\)](#) para abordar este desafío.

Es en este contexto donde surge el concepto de *single object tracking* (SOT), una técnica de visión por computador que se centra en el seguimiento de un solo objeto a lo largo de una secuencia de imágenes o video. El SOT se ha convertido en una herramienta fundamental para la detección y seguimiento de drones, ya que permite identificar y seguir un UAV específico en tiempo real, incluso en entornos complejos y dinámicos. Esta nueva técnica también se enfrenta actualmente a desafíos significativos, como la variabilidad en las condiciones ambientales de la escena del objeto, el reducido tamaño que presentan los drones cada vez más avanzados, y la necesidad de procesar grandes cantidades de datos en tiempo real para garantizar una respuesta rápida y efectiva.

En este trabajo de fin de grado, se explorará el uso de técnicas de aprendizaje profundo para abordar el problema del seguimiento de drones utilizando SOT. Se analizarán diferentes enfoques y algoritmos, evaluando su rendimiento en términos de precisión, velocidad y robustez en diversas condiciones.

1.2. Objetivos

Capítulo 2

ANTECEDENTES

2.1. Orígenes de la tecnología UAV

Desde hace dos siglos, el espacio aéreo ha dejado de ser una frontera inalcanzable para integrarse plenamente, junto al dominio terrestre y marítimo, como un área de proyección humana. En la actualidad, el cielo se consolida como un dominio estratégico fundamental para el transporte, las comunicaciones globales y la seguridad internacional. Sin embargo, y pese a lo antiintuitivo que pueda parecer, el concepto de aeronave no tripulada con fines estratégico-militares se remonta hasta comienzos del siglo pasado, coincidiendo con el desarrollo de la primera guerra mundial.

Desde el comienzo, demostraron ser prometedoras herramientas de reconocimiento aéreo en las pruebas de vuelo, pero no fue hasta el estallido de la guerra de Vietnam (1946-1954) cuando se desplegaron a gran escala y comenzaron a usarse con diversos fines tales como actuar como señuelos en combate o lanzar misiles contra objetivos fijos entre otros.

Tras este conflicto, muchos países comenzaron a invertir en su desarrollo, exploración y avance tecnológico, con nuevos modelos que mejoraban la resistencia y la capacidad de elevarse a mayor altitud. Actualmente, los drones mantienen muchos fines y aplicaciones reales, pero sin duda, su uso más conocido y relevante es el militar, en tareas de vigilancia, reconocimiento y ataques dirigidos.

A partir de noviembre de 2013 los microdrones y los UAVs fueron aprobados para su integración en el espacio aéreo de baja altitud (LAA) por la Administración Federal de Aviación (FAA). Esto ha provocado un crecimiento muy significativo en el número de drones registrados (más de 670.000 en EE. UU. en 2016 según el estudio de [Patel et al. \(2018\)](#)). Consecuentemente, surge una necesidad urgente de generar sistemas de legislación y regulación de estos vehículos a nivel nacional e internacional.

Sin embargo, esto deriva en varios problemas, como la dificultad de países no desarrollados para implementar leyes y sistemas de registro tan estrictos que rijan el uso de drones. Además, el tan elevado número de estos vehículos suele provocar la falta de personal de

cumplimiento activo para vigilar estas leyes, así como sistemas de detección operativos y eficientes, lo cual suele dejar a la policía o fuerzas del orden sin suficientes recursos para lidiar con estas amenazas.

El potencial de estas tecnologías para causar daños a la seguridad pública o nacional y para cometer delitos graves (tales como la violación de la privacidad, el transporte de sustancias ilegales, colisiones inadvertidas, el despliegue de armas explosivas o agentes químicos) es enorme. El ejemplo más recurrente de el daño que estas tecnologías pueden causar es el de los peligros de colisión, donde un artículo del IEEE en 2011 ([Moses et al. \(2011\)](#)) demostró que un dron de 2kg retiene la energía cinética equivalente a un proyectil antiaéreo de 20 mm (casi el doble de grande que uno de calibre 0,50).

2.2. Seguimiento de objetos individuales (SOT)

Dadas las numerosas problemáticas mencionadas en la anterior sección, surge la necesidad lógica de desarrollar sistemas automáticos capaces de detectar y seguir estos vehículos. Al eliminar el factor del error humano y las limitaciones ópticas, estos sistemas permiten mantener un espacio aéreo seguro, tanto en ámbitos de seguridad nacional como en la protección de la privacidad y el derecho a la intimidad, y recopilar pruebas forenses (estos sistemas pueden triangular la señal del dron para localizar al operador en caso de infracciones legales).

Es en este contexto donde surge el concepto SOT (Single Object Tracking). El seguimiento o trackeo de objetivos individuales es una tarea fundamental en el campo de la visión por computador o visión artificial (computer vision). Los sistemas SOT tienen como función rastrear un objeto concreto a lo largo de un video. El objetivo se especifica en el primer fotograma y debe ser reconocido y seguido en los fotogramas sucesivos. Esta técnica, junto con el seguimiento multi-objetivo (MOT), son las técnicas fundamentales en las aplicaciones de sistemas anti-UAVs.

Sin embargo, como en todos los campos de investigación; los sistemas y algoritmos SOT se enfrentan a numerosos desafíos y limitaciones, como los cambios repentinos de iluminación entre fotogramas, el ruido de fondo de las imágenes, la oclusión del objetivo y la escala del mismo entre otros. Debido a la presencia de estos factores en situaciones reales, los sistemas SOT deben cumplir tres características generales, según el estudio de [Soleimanitaleb and Keyvanrad \(2022\)](#):

- **Adaptabilidad:** El sistema debe ser capaz de rastrear el objetivo incluso en condiciones adversas como ruido de fondo, oclusión o cambios de iluminación.
- **Robustez:** Se debe garantizar que además de las alteraciones de entorno, el sistema debe adaptarse a cambios como los movimientos complejos y repentinos del objetivo, Algo muy común en los microdrones y UAVs. Para lograr esto, el sistema debe ser

capaz de detectar y rastrear las características aparentes del objetivo.

- **Eficiencia:** La mayoría de sistemas SOT se enfrenta a situaciones de rastreo en tiempo real, por lo que estos deben tener una alta velocidad general de procesamiento, lo que requiere implementar algoritmos de alto rendimiento.

2.3. Clasificación de métodos SOT

Debido a la gran cantidad de métodos distintos que se han desarrollado desde el inicio de esta disciplina, el poco tiempo que se lleva trabajando en esta y la gran evolución que ha experimentado, actualmente no existe una clasificación estandarizada de métodos de seguimiento aceptada universalmente. Sin embargo, para este trabajo se ha optado por seguir la taxonomía propuesta por Soleimanitaleb et al. en 2022 debido a su claridad, exhaustividad y a su reciente publicación (lo que permite tener en cuenta los métodos más actuales del campo). A continuación se muestra un diagrama de esta clasificación en la figura 2.1.




Figura 2.1: Taxonomía de métodos de seguimiento visual, [Soleimanitaleb and Keyvanrad \(2022\)](#).

2.3.1. Métodos basados en características

Esta familia de métodos suelen ser la vía más fácil y directa para abordar el problema del seguimiento de objetos. Se basan en una extracción previa de propiedades del objetivo

como el color, la textura o el flujo óptico para rastrearlo a lo largo de la secuencia de imágenes. Estas propiedades deben ser únicas para poder ser diferenciadas de otros objetos o del fondo de la imagen, actuando como signo de identidad del objetivo. Una vez se extraen estas características, se usan para encontrar la región más similar al objetivo en el siguiente frame siguiendo algún criterio de similitud, repitiéndose este proceso para cada frame de la secuencia. El principal inconveniente de estos métodos radica en la dificultad de definir características que sean simultáneamente discriminativas, robustas y estables frente a cambios de iluminación, escala, oclusiones o variaciones en la apariencia del objeto. A continuación, se describen los principales enfoques basados en características, centrándose en las tres propiedades más empleadas en este tipo de métodos: el color, la textura y el flujo óptico.

Color

El color suele ser la propiedad más relacionada con el aspecto visual del objetivo. Para representarlo como un dato estructurado se suele usar un histograma de color (representación gráfica de la distribución de colores en una imagen). El histograma muestra todos los colores presentes en la escena y su frecuencia de aparición (número de píxeles que corresponden a cada color). Un ejemplo de uso de histogramas para SOT es el método de Zhao en 2007 (2.2).

El proceso de seguimiento comienza con la identificación del objetivo en el primer frame introduciéndolo dentro de una *bounding box* (rectángulo que delimita la posición del objeto). Después, este se transforma a un histograma de color en el espacio de características apropiado. Ahora se pasa al siguiente frame, en el cual se introducen todos los posibles candidatos, los cuales son comparados de forma iterativa con el objetivo hasta encontrar el par con la máxima similitud entre histogramas. Una vez encontrada la instancia, se inserta el siguiente frame y se repite el proceso hasta llegar al último frame.

El principal inconveniente de este método es que, usando los histogramas de color, la representación depende únicamente del color del objeto e ignora el resto de propiedades como la forma o la textura del objeto, de forma que dos entidades diferentes pueden tener el mismo histograma.

Textura

En el contexto de la visión artificial, la textura se define como un patrón repetido de información o una disposición de una estructura concreta en intervalos regulares.

Esta propiedad no se extrae directamente, sino que es generada por técnicas de preprocesamiento de imágenes. Debido a la insuficiencia del color para identificar por sí solo a un mismo objeto en escenas diferentes, muchos métodos añaden la textura como característica para describir, junto al color, el contenido de la imagen.

La onda de Gabor es una de las características basadas en textura más usadas. La mayor ventaja de los filtros de Gabor es su invarianza ante cambios de iluminación, escala, rotación




Figura 2.2: Diagrama de flujo del seguimiento de objetos basado en histogramas en el espacio de características de gradiente (Zhao, 2007). Fuente: [Soleimanitaleb and Keyvanrad \(2022\)](#).

y traslación; lo que los hace muy útiles para los métodos de rastreo. Li et al. (2017) emplean filtros de Gabor para la extracción de características en tareas de reconocimiento facial (figura 2.3), demostrando su utilidad en tareas de visión por computador.




Figura 2.3: La Figura 2.3 muestra un ejemplo de extracción de características mediante descriptores basados en filtros de Gabor combinados con técnicas de codificación de textura (CS-LGBP), donde los filtros de Gabor se emplean como etapa inicial para capturar información de frecuencia y orientación. Fuente: [Li et al. \(2017\)](#).

Flujo óptico

En nuestro contexto, definamos el flujo óptico como el movimiento aparente de los patrones de luminosidad entre dos frames consecutivos. Los algoritmos que calculan el desplazamiento

de luminosidad para todos los píxeles de la imagen se conocen como algoritmos de flujo óptico denso, a diferencia de los algoritmos dispersos que calculan este desplazamiento solo para un número selectivo de píxeles. El principal inconveniente de usar el flujo óptico como identificador de movimiento en la escena es su incapacidad de diferenciar la variación de luminosidad causada por factores externos al movimiento, lo que puede llevar a errores.

Un ejemplo representativo de este enfoque es el método propuesto por Shi y Tomasi (1994), que combina la detección de puntos de interés con técnicas de flujo óptico para realizar el seguimiento de características a lo largo de una secuencia de imágenes. En la figura 2.4 pueden apreciarse los vectores que representan el movimiento de algunos píxeles de un objeto presente en un par de imágenes.




Figura 2.4: Ejemplo de flujo óptico denso entre dos frames consecutivos. Los vectores representan el desplazamiento de los patrones de intensidad de la imagen, permitiendo estimar el movimiento de los píxeles en la escena. Fuente: [Jaykumaran \(2025\)](#)

2.3.2. Métodos basados en segmentación

A la hora de rastrear un objeto en un video, muchas veces lo más simple es separar el primer plano del fondo de la escena, ya que los objetos que normalmente se mueven en una secuencia de imágenes suelen encontrarse en el primer plano. Esta es la idea fundamental de los métodos basados en segmentación, que separan los objetos presentes en el primer

plano del fondo de la escena para posteriormente seguirlos a lo largo de la secuencia. A continuación se describen los dos enfoques más comunes de este tipo de métodos.

Método ascendente (Bottom-Up)

En este tipo de técnica de seguimiento el proceso de segmentación y rastreo se consideran dos tareas diferentes. Primero se separa el fondo de la imagen de las zonas que contienen objetos en posible movimiento (primer plano). Estas zonas se agrupan en píxeles generando regiones que representan posibles objetos. A partir de este paso el método sigue la misma lógica que un método basado en características: Por cada región se extraen propiedades discriminativas (color, forma, tamaño...) y se comparan estas propiedades entre regiones de distintos frames para encontrar el candidato con la similitud más alta con el objetivo. 2.5




Figura 2.5: Esquema general del flujo de un método de seguimiento basado en segmentación *bottom-up*.

Métodos basados en estimación conjunta (Joint-Based)

A diferencia de los métodos ascendentes, los métodos de estimación conjunta mezclan los procesos de segmentación y rastreo, con el objetivo de solventar el problema de la dependencia de la segmentación previa y de la propagación de los errores de esta al seguimiento. Describamos el flujo general de este método de la siguiente forma: En el primer paso se

construye un modelo de apariencia del objeto usando una formulación probabilística. En la segunda fase es donde tiene lugar la segmentación usando este modelo de apariencia. En el tercer y último paso se realiza el seguimiento en sí (ver figura 2.6).




Figura 2.6: Esquema general del flujo de un método de seguimiento basado en segmentación *joint-based*.

2.3.3. Métodos basados en estimación

Esta rama de métodos formulan el problema de seguimiento como un problema de estimación en el cual el objeto a rastrear se representa con un vector de estado. Este vector describe el estado o comportamiento dinámico del objeto como la posición o la velocidad. El marco de trabajo más usado para el problema de la estimación del modo dinámico es traído de los métodos Bayesianos.

Los filtros bayesianos son ideales para este tipo de problemas ya que permiten una actualización constante del estado del objeto a medida que se reciben nuevas observaciones. El algoritmo general extrapolado al seguimiento es recursivo y se compone de dos pasos:

- **Predicción:** En esta fase se estima el estado del objeto en el siguiente frame a partir del estado previo, utilizando el modelo dinámico del sistema. Esta predicción incluye tanto la posición como otras variables relevantes (por ejemplo, velocidad) y su incertidumbre asociada.
- **Actualización:** En esta fase se incorpora la observación del frame actual mediante el modelo de observación, corrigiendo la estimación previa del estado del objeto y reduciendo la incertidumbre asociada a dicha predicción.

A continuación se describen los dos enfoques más comunes de este tipo de métodos.

Filtro de kalman

El filtro de kalman se usa para estimar el estado de un sistema lineal asumiendo errores gaussianos. Para ello, primero debe designarse un modelo dinámico del movimiento del objetivo. Esta técnica presenta importantes características de las que el seguimiento se puede beneficiar, como predecir la localización futura del objeto, corregir esta predicción basándose en nuevas medidas y reducir el ruido de las observaciones a partir de los diagnósticos incorrectos.




Figura 2.7: Flujo refinado del filtro de Kalman: La predicción física se corrige mediante la medición real para obtener el estado óptimo. Inspirado en [Soleimanitaleb and Keyvanrad \(2022\)](#)

En algunos trabajos se ha utilizado el filtro de Kalman para tareas de seguimiento (Gunjal et al., 2018; Taylor et al., 2021; Zhao et al., 2009).

Filtro de partículas

Uno de los principales inconvenientes de los métodos basados en el filtro de Kalman es su incapacidad para manejar sistemas complejos, es decir, sistemas que no se pueden expresar por la siguiente formulación:

$$x_k = Ax_{k-1} + w_k \quad (2.1)$$

donde x_k es el vector de estado del sistema en el instante k , A es la matriz de transición del estado, es decir, describe cómo se espera que el siguiente cambie siguiendo alguna ley física (normalmente cinemática básica); x_{k-1} es el estado del sistema en el instante $k - 1$ y w_k representa la incertidumbre o el ruido del proceso. Este ruido se asume normalmente aleatorio (gausiano).

Esta es la forma en la que se describen los sistemas lineales, presentes en situaciones de seguimiento sencillas y simples, sin mucho ruido, movimiento y forma del objeto constantes... Pero la realidad suele ser mucho más compleja. Es por eso que se ha considerado el uso de métodos basados en filtros de partículas para solventar este problema.

El filtro de partículas es un método de estimación recursivo basado en el método de cálculo estadístico de Monte Carlo, usado frecuentemente para modelos con formas de ruído

no gaussianas. La idea principal de este método radica en representar el sistema como una distribución de un conjunto de partículas. Cada partícula se asocia con un peso que refleja la probabilidad de que esta describa el estado real del sistema, o en nuestro caso, el estado del objeto a rastrear. Cuanto mayor sea la coincidencia entre el estado representado de la partícula y la observación del objeto, mayor será el peso asignado a esa partícula y viceversa. Para estimar el estado del objeto en el siguiente frame se realiza una suma ponderada de todas las partículas. Una vez obtenida esta predicción, todas las partículas se "mueven" siguiendo el modelo de estado, el cual añade un poco de ruido para cubrir posibles situaciones inesperadas (cambios bruscos de dirección o iluminación, oclusiones...).

Justo antes de comenzar el siguiente ciclo de predicción se lleva a cabo la fase conocida como Resampling, en la cual se eliminan las partículas cuyo peso no supera cierto umbral y se duplican las partículas con los pesos más altos hasta completar la población. De esta forma se evita el problema de la degeneración, que consiste en la convergencia de la población de partículas a un subconjunto de mejores candidatas que se mantienen invariantes a lo largo de la secuencia, dejando al margen el resto de partículas con pesos cada vez más bajos que no aportan información, restando generalización al método. Un ejemplo del uso de filtro de Partículas para tareas de rastreo es el método presentado por [Ding et al. \(2016\)](#) y mencionado en el artículo de [Soleimanitaleb and Keyvanrad \(2022\)](#). Este método utiliza una representación de histogramas para investigar los cambios de apariencia del objeto, especialmente su estado y su luminosidad. El flujo de este método queda representado en la figura 2.8.




Figura 2.8: Flujo general del método de filtro de partículas basado en histogramas ([Ding et al. \(2016\)](#)).

2.3.4. Métodos basados en aprendizaje automático

El aprendizaje automático es un campo que ha experimentado un notable desarrollo en los últimos años, dando lugar a importantes avances en diversos ámbitos como la ciencia, la tecnología y la gestión empresarial. Su objetivo principal es el desarrollo de algoritmos capaces de aprender patrones a partir de datos de entrenamiento y utilizarlos para resolver problemas de forma autónoma. En el contexto del seguimiento de objetos, estos modelos se emplean para aprender las características visuales y el comportamiento dinámico del objeto a partir de secuencias de imágenes que conforman el conjunto de entrenamiento.

Posteriormente, en la fase de test, utilizan lo aprendido para detectar y seguir el objeto en secuencias no vistas previamente.

En SOT, suele haber tres tipos de métodos basados en aprendizaje.

2.3.4.1. Métodos generativos

Los métodos generativos se centran en modelar la apariencia del objeto a rastrear y en encontrar, en cada frame, la región de la imagen que mejor se ajusta a dicho modelo. En el primer frame de la secuencia, se construye una representación del objeto a partir de características como histogramas de color, textura u otros descriptores visuales.

En los frames posteriores, se consideran distintas regiones candidatas dentro de la imagen, normalmente en torno a la posición estimada previamente. Para cada una de ellas, se evalúa su similitud con el modelo de apariencia, es decir, en qué medida la observación se ajusta a cómo debería verse el objeto según dicho modelo. Finalmente, se selecciona como nueva posición del objeto aquella región que presenta mayor correspondencia.

Aunque este esquema de evaluación de candidatos es común a otros enfoques, la característica distintiva de los métodos generativos reside en que se centran exclusivamente en modelar la apariencia del objeto, sin considerar explícitamente la información del fondo.

Sin embargo, resulta complicado verificar la precisión del modelo en la práctica ya que el objeto puede cambiar a lo largo de la secuencia modificando sus características, a partir de las cuales se generó el modelo. Son estos cambios en el video los que diferencian sistemas simples de sistemas complejos. Es por ello que se empezaron a introducir mecanismos de actualización online del modelo, de forma que ya no se genera un modelo al principio y este se mantiene estático a lo largo de la secuencia, sino que en la propia fase de testeo, el algoritmo aprende nuevas representaciones visuales del primer plano de la región del objeto ignorando la influencia del fondo de la imagen y actualizando así el modelo de apariencia a lo largo de la secuencia.

Un ejemplo del uso de métodos generativos para tareas de seguimiento es el método de [Bao et al. \(2012\)](#).

2.3.4.2. Métodos de aprendizaje reforzado

un modelo de aprendizaje reforzado aprende mediante prueba y error a partir de la toma de decisiones secuenciales para seguir al objeto. Este método define un agente encargado de tomar las decisiones. Por cada frame, el agente adopta el estado del objeto (bounding box, características...) y aplica transformaciones a este estado (mover la caja de delimitación, cambiar su tamaño...). Por cada transformación, el agente evalúa su decisión a través de una función de recompensa. Esta función premia las acciones que acercan el estado transformado de la caja al estado actual y penaliza las que lo alejan. De esta forma, el agente aprende a tomar decisiones que maximicen la recompensa acumulada.

La idea clave es que el agente no aprende características del objeto o del sistema. No hay un modelo de apariencia ni un modelo dinámico del sistema. El agente aprende a tomar decisiones, es decir, a llevar a cabo acciones sobre el estado del sistema sin necesidad de modelar explícitamente su contenido. Esto tiene grandes ventajas como la capacidad del agente para adaptarse situaciones complejas como trayectorias impredecibles o movimientos bruscos. Al depender únicamente del criterio de decisión, el agente se centra más en hacerlo bien que en entender qué hace realmente. Sin embargo, el principal inconveniente de este método es la dificultad de diseñar una función de recompensa adecuada que guíe el aprendizaje del agente hacia un comportamiento deseado. Además, el proceso de entrenamiento puede ser largo y requerir una gran cantidad de datos para que el agente aprenda a tomar decisiones efectivas.

Un artículo que trabaja con métodos de aprendizaje reforzado para tareas de seguimiento es el de [Choi et al. \(2018\)](#). Este método se compone de dos redes neuronales: una red de emparejamiento que genera mapas de predicciones a partir del estado del objeto, y una red de política que evalúa estas predicciones generando una puntuación para cada una de estas. La predicción de mayor puntuación se selecciona como la nueva posición del objeto en el siguiente frame. Esta red de política es entrenada para funcionar en diversas situaciones.




Figura 2.9: Ejemplo del proceso de decisión en un método de seguimiento basado en aprendizaje por refuerzo. A partir del estado actual, el agente evalúa distintas acciones que generan nuevas hipótesis de localización. Cada una de estas hipótesis se asocia a una función de valor o recompensa (visualizada mediante mapas de calor), que mide la calidad de la localización.

2.3.4.3. Métodos discriminativos

A diferencia de los métodos generativos que primero establecen un modelo probabilístico para la estructura subyacente a los datos (al estado del objetivo) y después buscan la región que mejor encaje con este modelo, los métodos discriminativos consideran la tarea de seguimiento como un problema de clasificación binaria, en la que se busca separar (discriminar) al objeto del fondo de la imagen.

Como describe Wang (sf), los métodos discriminativos se basan en el aprendizaje de un modelo capaz de asignar a cada muestra de datos $\mathbf{x}$ una etiqueta de clase y . En su forma más general, estos modelos pueden interpretarse como funciones que aproximan directamente la relación entre las observaciones y las etiquetas, ya sea de forma determinista o mediante el modelado de la probabilidad condicional $p(y | \mathbf{x})$.

El objetivo de estos métodos es aprender fronteras de decisión que separen las distintas clases a partir de los datos de entrenamiento, prestando especial atención a aquellas muestras cercanas a dichas fronteras.

En el contexto del seguimiento de objetos, esta formulación se traduce habitualmente en un problema de clasificación binaria, en el que el modelo debe distinguir entre el objeto de interés (clase positiva) y el fondo o distractores (clase negativa). De este modo, el proceso de tracking consiste en evaluar distintas regiones candidatas y seleccionar aquella que el modelo clasifica como objeto con mayor confianza.

Este tipo de métodos suelen a su vez dividirse en dos categorías: aprendizaje superficial y aprendizaje profundo.

Aprendizaje superficial

Como se ha visto anteriormente, un problema de seguimiento puede ser considerado como un proceso de toma de decisiones en el que un clasificador se entrena para aprender a discriminar entre el objeto y el fondo. Después, en la etapa de prueba, el clasificador decide si un candidato es objeto o no. Este es el enfoque seguido por los métodos de aprendizaje superficial. En ellos, además, las características del objeto se definen manualmente y se extraen durante el entrenamiento y el test.

El flujo general de este tipo de métodos comienza con la definición de un área de búsqueda alrededor de la posición estimada del objeto en el primer frame. Tras definir este área, se generan n regiones candidatas a representar la posición del objeto. Para traducir este problema a clasificación binaria se define la región del objeto como clase positiva y al resto de regiones del área de búsqueda como clase negativa. Cada región candidata se evalúa según la función de clasificación $p(y = 1 | \mathbf{x})$, donde $y = 1$ representa la clase positiva (objeto) y $\mathbf{x}$ es el vector de características extraídas de la región candidata. La posición del objeto se define como $\mathbf{x}^* = \arg \max_{\mathbf{x}_i} p(y = 1 | \mathbf{x})$, es decir, la región candidata que maximiza la probabilidad de ser clasificada como objeto, también conocido como el máximo local de la región de

búsqueda.

Este enfoque fue utilizado para tracking por [Tian et al. \(2007\)](#) e incorporaron un SVM como clasificador. Las máquinas de soporte vectorial (SVM) son uno de los clasificadores por excelencia en este tipo de métodos. Estos algoritmos tienen como objetivo encontrar el hiperplano óptimo que separa dos clases de datos con el máximo margen posible en un espacio de características. Los vectores de soporte se pueden definir como los puntos más cercanos a la frontera de decisión, es decir, los que están en la zona de mayor ambigüedad entre clases. Es por esto que para que el clasificador aprenda el mayor número de datos cercanos a la ambigüedad aproximándose así a la frontera de decisión resulta esencial definir la antes mencionada como "área de búsqueda".

En la figura 2.10 se muestra esquema general de este flujo.




Figura 2.10: Resumen del uso de máquinas de soporte vectorial para tareas de seguimiento [Tian et al. \(2007\)](#).

Aprendizaje profundo

Las redes neuronales artificiales se inspiran generalmente en la estructura de los circuitos neuronales del cerebro humano, cuyo funcionamiento radica en la compleja transmisión de señales químicas y eléctricas a través de redes distribuidas de células nerviosas (neuronas). En el aprendizaje profundo, estas señales se interpretan como las salidas ponderadas de muchas operaciones matemáticas anidadas y distribuidas entre numerosas capas intermedias de procesamiento que en conjunto conforman la red neuronal (ver figura 2.11).

De forma más específica, podemos entender un modelo de *deep learning* como una serie intrincada de ecuaciones anidadas que asignan una entrada a una salida. Las relaciones entre estas ecuaciones se organizan en capas, donde la salida de cada neurona en una capa se convierte en la entrada ponderada para todas las neuronas de la siguiente capa. Esta ponderación se ajusta mediante un valor llamado peso. Además, el punto de activación de cada neurona viene determinado por una función de activación que a su vez depende de otro nuevo valor conocido como sesgo. De esta forma, el aprendizaje de la red puede entenderse como el proceso de ajuste de sus parámetros internos, principalmente pesos y sesgos, mediante algoritmos de optimización. Este ajuste modifica la forma en que la red

transforma las entradas en salidas, con el objetivo de minimizar el error entre las predicciones del modelo y los valores esperados.




Figura 2.11: Ejemplo de red neuronal estándar con 3 capas ocultas IBM (sf).

En el contexto de la visión artificial, las recientes técnicas de aprendizaje profundo han demostrado ser altamente efectivas, en concreto aumentando significativamente la precisión en los métodos de seguimiento de objetos.

Mientras que en los métodos de aprendizaje superficial requieren de características importantes y discriminativas extraídas manualmente por profesionales, los métodos de aprendizaje profundo son capaces de extraer estas características de forma autónoma.

Debido a la notable mejora que supone el uso de estos modelos para tareas de SOT, nos centraremos más detenidamente en la clasificación de este tipo de métodos a continuación.

Comencemos esta clasificación con dos categorías genéricas de métodos de aprendizaje profundo: Métodos basados en la extracción de características y métodos de extremo a extremo.

Métodos basados en extracción de características

Desde la experiencia experimental a lo largo del desarrollo de los algoritmos clásicos de seguimiento (descritos en las secciones anteriores) se puede observar que cualquier desarrollo o mejora en la etapa de extracción de características suele traducirse en una mejora directamente proporcional en la precisión del propio seguimiento. Es por esta razón que, aprovechando la gran habilidad que presentan las técnicas de aprendizaje profundo para la extracción de características y clasificación de imágenes, se pueden implementar métodos de seguimiento basados en redes neuronales profundas para la extracción de características, conocidos como redes de extracción (*feature extraction networks*).

Este tipo de métodos separan el proceso de seguimiento en dos secciones: detección y seguimiento.

En fase de detección, se utilizan redes de extracción para obtener características profundas. Por otro lado, en la fase de seguimiento se pueden utilizar métodos clásicos (filtros de Kalman, SVM...) o métodos basados en aprendizaje profundo (Redes convolucionales, modelos LSTM...).

Usualmente suelen utilizarse redes neuronales convolucionales (CNN) para la extracción de características, siendo este tipo de redes idóneas para el procesamiento específico de imágenes. El flujo de obtención de estos atributos suele seguir una complejidad creciente a medida que se avanza por las capas de la red: las primeras capas pueden aprender a detectar bordes simples (líneas, contornos). En capas más profundas, la red va aprendiendo patrones más complejos y texturas, hasta llegar a las capas finales donde la red ya es capaz de identificar formas y objetos más complejos.

Una vez la CNN extrae las características de la imagen, estas se utilizan para representar al objeto en el espacio de características y emplear esta representación para comparar la imagen actual con la plantilla del objeto que el tracker ha aprendido (ver figura 2.12).




Figura 2.12: Flujo general de un método de seguimiento profundo basado en extracción de características y modelado temporal. [Ghaemmaghani \(2017\)](#)

Métodos de extremo a extremo

Este tipo de métodos se caracterizan por entrenar una única red para dirigir todo el proceso de seguimiento, es decir, desde la etapa de extracción de características hasta la etapa de evaluación de candidatos. Siguiendo la clasificación de [Soleimanitaleb and Keyvanrad \(2022\)](#), podemos dividir este tipo de métodos tres categorías: redes siamesas, aprendizaje basado en parches (*patch learning*) y trackers basados en grafos.

Redes siamesas

Las redes siamesas son un tipo especial de arquitectura de red neuronal diseñada para comparar dos entradas y producir una salida. La red procesa cada entrada por separado para producir *embeddings* (vectores de características). Luego, estos embeddings se comparan utilizando una función de similitud o una métrica de distancia [Chierchia \(2025\)](#).

El objetivo principal de la red es minimizar la distancia entre embeddings de entrada similares y maximizar la distancia entre los embeddings de entrada diferentes. Esto obliga a la red a aprender a extraer las características más esenciales de las entradas para su comparación. Esto resulta especialmente útil en tareas en las que la cantidad de datos de entrenamiento etiquetados es limitada, ya que la red se centra más en aprender comparaciones relativas que en comparar características absolutas. Una vez entrenadas, pueden generalizar a clases desconocidas durante su entrenamiento.

Este tipo de red suele componerse de dos ramas idénticas, es decir, dos subredes (normalmente CNNs) con los mismos pesos y arquitectura (de ahí el nombre de "siamesas"), cada una de ellas encargada de procesar una de las entradas y generar una representación. Luego, estas representaciones se comparan mediante una función de similitud. En tracking, esta comparación suele generar un mapa de respuesta en el que se ponera una puntuación a cada región en función de su probabilidad de contener al objeto. Se devuelve la región con mayor puntuación. La arquitectura genérica de una red siamesa se muestra en la figura [2.13](#).

Las ramas de esta red suelen ser CNNs compuestas de tres partes (ver figura [2.14](#)):

- **Backbone:** Este es el esqueleto de la red, una serie de capas convolucionales y de puesta en común (*pooling*) encargadas de extraer las características de la imagen.
- **Neck:** Un pequeño número de capas para procesar aún más las características extraídas por el backbone y generar una representación más compacta y discriminativa de la imagen. Normalmente se utiliza una capa de aplanamiento (*flattening*), seguida de una o más capas totalmente conectadas con activaciones no lineales.
- **Head:** Es el conjunto final de capas encargadas de preparar los embeddings para su comparación acorde a una función de pérdida seleccionada. Normalmente esto involucra a una capa de normalización. Normalmente esta parte final de la red se comparte entre las dos ramas para fusionar ambas representaciones.

En el contexto del seguimiento de objetos, muchos estudios recientes han utilizado redes siamesas para proponer mejoras significativas en la precisión de los trackers. Un ejemplo de ello es el método GOTURN de [Held et al. \(2016\)](#). este tracker propone un método de entrenamiento offline capaz de detectar nuevos objetos a 100 FPS durante la etapa de testeo.

Este modelo destaca por ser de regresión directa, en lugar de de clasificador de candidatos: El modelo recibe como entrada dos recortes, el objeto en el frame anterior y el área de




Figura 2.13: Representación de la estructura del modelo de red neuronal siamesa. Los datos se procesan de izquierda a derecha. El valor de la distancia coseno es una medida de la similitud entre el par de instancias de datos de entrada, como resultado final. [Chicco \(2021\)](#).




Figura 2.14: Representación de la estructura del modelo de red neuronal siamesa. Los datos se procesan de izquierda a derecha. El valor de la distancia coseno es una medida de la similitud entre el par de instancias de datos de entrada, como resultado final. [Chicco \(2021\)](#).

búsqueda en el frame actual. Ambos pasan por capas convolucionales (ramas) para extraer características. Después, capas totalmente conectadas (*fully-connected layers*) combinan esa información. Para la salida, el modelo predice directamente las coordenadas de la nueva bbox dentro de la región de búsqueda, en lugar de evaluar muchas ventanas candidas (de ahí su consideración como regresor directo). La arquitectura de este método se describe en la figura 2.15.




Figura 2.15: Se introduce en la red una zona de búsqueda del fotograma actual y un objetivo del fotograma anterior. La red aprende a comparar estos recortes para encontrar el objeto objetivo en la imagen actual [Held et al. \(2016\)](#).

Este modelo a su vez destaca por entrenarse de forma *offline*. Esto quiere decir que los pesos adoptados durante el entrenamiento (con vídeos e imágenes anotadas) quedan congelados en la etapa de test, es decir, el modelo no se actualiza durante el seguimiento. La principal ventaja de esta estrategia es que al no clasificar múltiples parches en la fase de test, el modelo consigue una velocidad muy alta, alrededor de 100 fps en este caso. Esto es algo crucial en tracking ya que la mayoría de aplicaciones de estos métodos suelen implicar situaciones donde se requiere seguimiento en tiempo real. Por otro lado, al depender de una región de búsqueda local basada en la posición anterior, la predicción puede fallar ante movimientos rápidos, oclusiones largas o salidas de escena.

Capítulo 3

OBJETIVOS

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac

pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Capítulo 4

MATERIALES Y MÉTODOS

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac

pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Capítulo 5

RESULTADOS

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac

pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Capítulo 6

CONCLUSIONES

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac

pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Bibliografía

- Bao, C., Wu, Y., Ling, H., and Ji, H. (2012). Real time robust l1 tracker using accelerated proximal gradient approach. In *2012 IEEE Conference on Computer Vision and Pattern Recognition*, pages 1830–1837. IEEE.
- Chicco, D. (2021). *Siamese Neural Networks: An Overview*, pages 73–94. Springer US, New York, NY.
- Chierchia, G. (2025). Siamese network. <https://perso.esiee.fr/~chierchg/deep-learning/tutorials/metric/metric-1.html>. Deep Learning. Consultado el 6 de mayo de 2026.
- Choi, J., Kwon, J., and Lee, K. M. (2018). Real-time visual tracking by deep reinforced decision making.
- Ding, D., Jiang, Z., and Liu, C. (2016). Object tracking algorithm based on particle filter with color and texture feature. In *2016 35th Chinese Control Conference (CCC)*, pages 4031–4036.
- Ding, Z., Lai, Z., Li, S., Li, P., Yang, Q., and Wong, E. (2024). Confidence trigger detection: Accelerating real-time tracking-by-detection systems. In *2024 5th International Conference on Electronic Communication and Artificial Intelligence (ICECAI)*, page 587–592. IEEE.
- Felsberg, M., Kristan, M., Matas, J., Leonardis, A., Pflugfelder, R., Häger, G., Berg, A., Eldesokey, A., Ahlberg, J., Čehovin Zajc, L., Vojír, T., Lukežič, A., Fernandez Dominguez, G., Petrosino, A., Garcia-Martin, A., Montero, A., Varfolomeiev, A., Erdem, A., Han, B., and He, Z. (2016). The thermal infrared visual object tracking vot-tir2016 challenge results. volume 9914, pages 824–849.
- Ghaemmaghami, M. P. (2017). Tracking of humans in video stream using lstm recurrent neural network.
- HD Drones (s.f.). Historia de los drones. <https://huescadrones.es/hddrones/historia-de-los-drones/>. Asociación HD Drones. Consultado el 25 de marzo de 2026.

- Held, D., Thrun, S., and Savarese, S. (2016). Learning to track at 100 fps with deep regression networks.
- Hou, F., Zhang, Y., Zhou, Y., Zhang, M., Lv, B., and Wu, J. (2022). Review on infrared imaging technology. *Sustainability*, 14(18).
- IBM (s.f.). Deep learning. <https://www.ibm.com/es-es/think/topics/deep-learning>. IBM Think. Consultado el 4 de mayo de 2026.
- Jaykumaran (2025). MAST3R and MAST3R-SfM explanation: Image matching and 3d reconstruction results. <https://learnopencv.com/mast3r-sfm-grounding-image-matching-3d/>. LearnOpenCV. Consultado el 20 de abril de 2026.
- Li, C., Wei, W., Jiaxue, L., and Song, W. (2017). A cloud-based monitoring system via face recognition using gabor and cs-lbp features. *The Journal of Supercomputing*, 73.
- Moses, A., Rutherford, M. J., and Valavanis, K. P. (2011). Radar-based detection and identification for miniature air vehicles. In *2011 IEEE International Conference on Control Applications (CCA)*, pages 933–940.
- Patel, J. S., Fioranelli, F., and Anderson, D. (2018). Review of radar classification and rcs characterisation techniques for small uavs or drones. *IET Radar, Sonar & Navigation*, 12(9):911–919.
- Soleimanitaleb, Z. and Keyvanrad, M. A. (2022). Single object tracking: A survey of methods, datasets, and evaluation metrics. *CoRR*, abs/2201.13066.
- Tian, M., Zhang, W., and Liu, F. (2007). On-line ensemble svm for robust object tracking. In Yagi, Y., Kang, S. B., Kweon, I. S., and Zha, H., editors, *Computer Vision – ACCV 2007*, pages 355–364, Berlin, Heidelberg. Springer Berlin Heidelberg.
- Wang, R. (s.f.). Support vector machines. <https://pages.hmc.edu/ruye/MachineLearning/lectures/ch9/node1.html>. Harvey Mudd College. Consultado el 21 de abril de 2026.
- Xie, B., Zhang, C., Wang, F., Liu, P., Lu, F., Chen, Z., and Hu, W. (2025). Cst anti-uav: A thermal infrared benchmark for tiny uav tracking in complex scenes.